

Coleta de Dados

O conjunto de dados utilizado reúne informações históricas de vendas de jogos lançados para PlayStation 3, PlayStation 4 e PlayStation 5.

Foram utilizadas informações como:

- Plataforma
- Gênero
- Desenvolvedora
- Publicadora
- Ano de lançamento
- Nota dos usuários
- Nota da crítica
- Número de avaliações
- Vendas globais

Antes da modelagem foi realizado tratamento dos dados, remoção de inconsistências, preenchimento de valores ausentes e transformação das variáveis categóricas utilizando OneHotEncoder.

Modelagem

Foi construída uma solução de Machine Learning para prever as vendas globais de novos jogos.

Os seguintes modelos foram avaliados:

- Random Forest
- Gradient Boosting
- XGBoost

Para garantir uma avaliação robusta foi utilizada validação cruzada (KFold).

As métricas avaliadas foram:

- MAE
- RMSE
- R^2

Também foi utilizada uma Pipeline de pré-processamento contendo:

- Imputação de dados ausentes
- Padronização de variáveis numéricas
- Codificação One-Hot das variáveis categóricas

Conclusões

Os resultados demonstraram que modelos baseados em árvores de decisão apresentaram excelente desempenho para previsão das vendas.

O XGBoost e o Gradient Boosting alcançaram os maiores valores de R^2 (0,993), indicando elevada capacidade de explicar a variabilidade das vendas.

A análise da importância das variáveis mostrou que fatores como plataforma, gênero, desenvolvedora e avaliações exercem forte influência sobre o desempenho comercial de um jogo.

Este projeto demonstra a aplicação completa de um fluxo de Ciência de Dados, desde a coleta e preparação dos dados até a construção, avaliação e interpretação de modelos preditivos, utilizando boas práticas amplamente empregadas no mercado.